Задание 1. Инструменты и ручной цикл

12 октября 2026 • GPT-6 Luna / OpenRouter • 60 основных и 3 диагностических траектории

Пять инструментов над исходной базой Ростова (8860 мест, OSM/ODbL): **count_places, find_places, nearest_place, geocode, place_details**. Цикл написан без агентного фреймворка: OpenAI-клиент, строгие схемы, проверка аргументов, ошибки как наблюдения, JSONL и usage. Лимит - 6 шагов; на шаг допускаются до 3 транспортных попыток. Списки ограничены 10 строками, расстояния - метры по прямой.

Протокол и метрики

Десять фиксированных задач по три независимых повтора на вариант. Короткий вариант содержит одну фразу, полный - назначение, границы применимости, единицы и пример. Менялось только описание; схемы и настройки одинаковы. Порядок пар AB/BA чередуется; reasoning_effort=none, temperature=0.2. Проверяются вызовы, аргументы и заранее заданные факты по базе.

Метрика	Короткие	Полные
pass@1	100.0%	100.0%
pass^3	100.0%	100.0%
Инструмент и аргументы	100.0%	100.0%
95% Вильсон (выбор инструмента)	88.6%-100%	88.6%-100%
Средние входные токены	1976.0	3279.9
Средние выходные токены	78.0	77.8
Средние суммарные токены	2054.1	3357.7
Средние шаги	2.30	2.30
Средняя цена задачи, USD	0.000224	0.000085

pass@1 = успешные отдельные попытки / 30. pass^3 = доля из 10 задач с успехом всех трёх повторов, а не куб среднего. Шаг включает финальный ответ. Вильсон: z=1.96, 30/30 правильных выборов; повторы одной задачи зависимы, поэтому интервал описательный. Проверка фактов не оценивает всю семантику ответа.

Окупились ли полные описания

Прирост правильных выборов: **0 из 30**. Дополнительный вход: **1303.9 токена** на задачу. Фактическая цена правильной попытки снизилась с $0.000224 до $0.000085 (**62.2%**); экономия на 30 попытках - **$0.004183**. По цене полного прогона описания окупились на этой выборке, по качеству прироста нет.

Средние кэшированные входные токены: 179.3 против 3166.3. Кэш провайдера не контролировался: экономия отражает наблюдавшийся кэш, а не доказанную пользу длинного текста. Цена взята из usage.cost; три повтора и десять задач недостаточны для обобщения.

Ошибки, проверка и воспроизведение

Три диагностические неудачи не входят в A/B-метрики

После исправления оценщика естественных неудач в 60 траекториях не осталось. Для проверки устойчивости выполнены три явно помеченных сценария с настоящей моделью и искусственно внесёнными сбоями. Их нельзя трактовать как частоту ошибок модели на обычных задачах.

1. Недоступная база - ошибка среды

T01, full. Модель дважды вызвала count_places(kind=pharmacy, only_24_7=false). Диспетчер каждый раз вернул OSError как наблюдение. После трёх шагов модель честно завершила ответ без проверяемого числа; задача не решена, процесс не упал. Ложный успех не засчитан. Источник: T01_full_1_database_unavailable.jsonl.

2. Повреждённый kind - не те аргументы

T01, full. Модель запросила корректный kind=pharmacy, но диагностический диспетчер заменил его на «аптека». Валидатор дважды вернул ValidationError. Финальный ответ не выполнил задачу; цикл сохранил ошибки вместо падения. Это контролируемый сбой интерфейса, а не неправильные аргументы, выбранные моделью. Источник: T01_full_1_invalid_arguments.jsonl.

3. Повторяемое наблюдение - зацикливание

T01, full. Инструмент трижды возвращал retryable=true и требование повторить вызов. Диагностическая инструкция предписывала повторять до успеха. Модель трижды запросила тот же count_places; max_steps=3 остановил цикл. Источник: T01_full_1_retry_loop.jsonl. Предохранитель ограничил и число шагов, и стоимость.

Исправление оценщика и прозрачность данных

Первоначальный оценщик ошибочно отверг 18 правильных ответов из-за записи «с 08:00 до 21:00» и дефисов в телефонах. Нормализация применена симметрично, без повторных модельных запросов. Оригинальные оценки сохранены в records.v1.json и summary.v1.json; новые добавлены событиями reevaluation. Вопросы, описания, ответы и tool_calls не менялись. Есть отдельные тесты верных и неверных расписаний и телефонов.

Воспроизведение

uv run python check.py --n 3 - из корня репозитория; ключ вводится скрыто или задаётся в окружении/.env. uv.lock фиксирует зависимости. Инженерные проверки: **uv run python -m unittest test_assignment -v** (7 тестов; изолированное окружение также проверено). Журналы: runs/20261012T182559Z, метрики: summary.json, параметры и отпечатки: experiment.json. Ключи и HTTP-заголовки не сохраняются.

Всего в этом эксперименте: **$0.009737**, из них диагностика - **$0.000478**. Расходы прежнего ноутбука сюда не входят.